



Reviewer Assignment Automatisation Project

Présenté par:
Mohsen Allani
Mariam Boughizene

Encadré par:
Dr. Mariem Gzara

2025-2026





Plan du Présentation

1 business understanding

2 Processus / architecture / flux global

3 Collecte des données

4 Nettoyage des données

5 Exploration des données

6 Data wrangling and feature engineering

7 Apprentissage

8 Analyse comparative

9 Conclusion

Définition de la problématique

Introduction :

- Dans les séminaires scientifiques, les articles soumis doivent être évalués par des reviewers spécialisés selon leur domaine (informatique, médecine, droit, économie, etc.).
- L'attribution actuelle des articles aux reviewers est manuelle, ce qui entraîne :
 - une perte de temps,
 - des erreurs d'affectation (mauvais domaine),
 - une répartition déséquilibrée de la charge entre reviewers.

Besoin principal :

- Automatiser l'affectation des articles aux reviewers compétents afin d'améliorer l'efficacité et la fiabilité du processus.

Objectif du projet :

- Analyser des articles scientifiques en arabe (titre, résumé, mots-clés) pour recommander automatiquement le reviewer le plus approprié.
- Comprendre le lien entre le contenu textuel des articles et le domaine d'expertise des reviewers.

Formulation du problème :

- Il s'agit d'un problème de classification supervisée : à partir du texte d'un article, prédire le reviewer le plus adapté.



Processus / architecture / flux global

Vue d'ensemble du pipeline :

- Collecte des données (articles, reviewers, métadonnées)
- Nettoyage et prétraitement linguistique (arabe)
- Feature engineering & vectorisation (TF-IDF, encodage du domaine, facteur d'impact)

Apprentissage supervisé (Logistic Regression, Random Forest)

- Validation et mesure métier (Top-K, score métier)
- Recommandation des Top-N reviewers pour chaque article

Collecte des données

Objectif

- Construire une base de données fiable d'articles scientifiques en arabe
- Associer chaque article à son reviewer afin d'entraîner un modèle de recommandation supervisé

Démarche

- Collecte manuelle et contrôlée des données
- Extraction soigneuse des informations textuelles et contextuelles
- Structuration des données dans un format tabulaire
- Veille à la diversité des domaines scientifiques

Sources

- Sites web et journaux scientifiques arabes reconnus couvrant plusieurs domaines : Médecine, Droit, Ingénierie, Sciences humaines
- Données incluant articles en arabe, reviewers et facteur d'impact

Outils utilisés

- Navigateurs web : exploration et collecte
- Excel : structuration et organisation initiale des données

Résultat

- 400 articles scientifiques ,70 reviewers

Attributs principaux :

- title, abstract,
keywords, domain, reviewer_profession, Impact_Factor, reviewer
(variable cible)

Nettoyage des données

Objectif

- Obtenir un jeu de données cohérent, complet et exploitable pour la modélisation

Prétraitement structurel

- Suppression des doublons (articles avec le même title)
- Suppression des lignes avec : reviewer manquant ,reviewer_profession manquante
- Imputation de Impact_Factor : Remplacé par la moyenne des articles du même reviewer
- Gestion des champs textuels manquants :
 - 1.abstract $\leftarrow$ concaténation (title + keywords)
 - 2.title $\leftarrow$ keywords
 3. Suppression si informations textuelles insuffisantes
- Imputation du domain : Domaine majoritaire des articles du même reviewer

Résultat du nettoyage

- 339 articles scientifiques
- 66 reviewers distincts

Prétraitement linguistique

- Normalisation du texte arabe (lettres, diacritiques, ponctuation)
- Tokenisation morphologique avec CAMeL Tools
- Lemmatisation pour réduire la variabilité lexicale
- Traitement spécifique des keywords (préservation des termes scientifiques)
- Suppression des stop words : Liste standard arabe ,Stop words personnalisés basés sur la distribution par domaine

Exploration des données

Objectif

- Analyser la structure finale du jeu de données après nettoyage
- Vérifier l'équilibre entre domaines et reviewers

Répartition des articles par domaine

- Après le nettoyage, la distribution des articles reste équilibrée entre les domaines :
- DomaineNombre d'articles Médecine 89, Droit 85, Ingénierie 84, Sciences humaines 81

Nombre total de domaines : 4

Équilibrage par reviewer

Nous avons développé une fonction dédiée pour supprimer les reviewers ayant moins de 3 articles pour

- éviter un apprentissage biaisé,
- garantir que chaque classe (reviewer) dispose d'assez d'exemples,
- améliorer la stabilité et la généralisation du modèle

Feature engineering

Division du jeu de données

Séparation en train et test (cross validation = 5)

Transformation & structuration

- Champs textuels utilisés : title, abstract, keywords, reviewer_profession
- Champs numérique utilisés : Impact_Factor
- Conversion en texte brut puis concaténation en un champ textuel unique

Représentation numérique

- TF-IDF avec : uni-grammes et bi-grammes ,max 5000 features (réduction automatique)
- Chaque article → vecteur numérique textuel

Traitement spécifique du domaine

- Le domaine scientifique est traité séparément par One-Hot Encoding

Justification :

- en TF-IDF, son poids serait trop faible
- or le domaine est clé pour la recommandation

Les features du domaine sont pondérées plus fortement

Variables numériques

- Impact Factor conservé et normalisé
- Ajout direct à la représentation finale

Combinaison finale & pondération

- Concaténation :
 - TF-IDF (texte)
 - One-Hot Encoding (domaine, pondéré)
 - variables numériques
- Résultat :
- `X_train_final / X_test_final`
- format directement exploitable par les modèles ML

Apprentissage

Premier modèle : Régression Logistique

Le premier modèle utilisé est une régression logistique multiclasse. Ce modèle linéaire constitue une base de référence robuste et interprétable.

Les résultats obtenus sont les suivants :

- Score métier final : 0.93
- Accuracy classique : 0.5294
- Top-1 Accuracy : 0.5294
- Top-3 Accuracy : 0.7294
- Top-5 Accuracy : 0.8353

Ces résultats montrent que, bien que l'accuracy classique soit relativement modérée, le modèle est capable de proposer des reviewers pertinents dans les premières recommandations. Le score métier élevé confirme que les reviewers suggérés appartiennent majoritairement au bon domaine.

Deuxième modèle : Random Forest

Le second modèle est une Random Forest, capable de capturer des relations non linéaires complexes entre les caractéristiques. Nous avons également pris en compte le déséquilibre des classes grâce au paramètre `class_weight`.

Les performances obtenues sont nettement supérieures :

- Score métier final : 1.00
- Accuracy classique : 0.9176
- Top-1 Accuracy : 0.9176
- Top-3 Accuracy : 1.0000
- Top-5 Accuracy : 1.0000

Ces résultats indiquent que le modèle parvient non seulement à identifier le reviewer exact dans la majorité des cas, mais aussi à proposer des listes de recommandations parfaitement pertinentes.

Analyse comparative

La comparaison entre les deux modèles met en évidence plusieurs points :

- la régression logistique offre une bonne base mais reste limitée face à la complexité des données textuelles,
- la Random Forest exploite plus efficacement la richesse des features combinées (texte, domaine, facteurs numériques),
- les métriques métier et Top-k sont plus représentatives de la performance réelle du système que l'accuracy seule.

Conclusion

Bilan :

- Construction d'un pipeline complet de recommandation de reviewers à partir de textes arabes
- Traitement avancé du langage (normalisation, lemmatisation, stopwords, TF-IDF)
- Modèle Random Forest très performant (Top-K et score métier)
- Apports métier : Accélération de l'affectation des reviewers Amélioration de la cohérence des décisions éditoriales

Limites & perspectives :

- Données limitées à un seul contexte et langue
- Pistes : prise en compte de l'historique des décisions, feedback des reviewers, extension à d'autres langues ou revues

MERCI !