

République Tunisienne

Ministère de l'Enseignement Supérieur et de la Recherche
Scientifique

Université de Monastir

Institut Supérieur d'Informatique et de Mathématiques de
Monastir

Département Informatique



Rapport de projet traitement de données

Présenté par:

Mohsen Allani

Mariem Boughizene

**Attribution des reviewers pour des articles
scientifiques à l'aide de l'apprentissage
automatique**

Encadré par:

Mme. Mariem Gzara

Année universitaire : 2025-2026

Table des matières

1. Business Understanding and problem formulation :	2
2. Data collection	3
A. Collecte des données	3
B. Démarche de collecte	3
C. Sources des données	3
D. Outils utilisés	3
E. Résultat de la collecte	4
3. Data Understanding (Compréhension des données)	4
4. Data cleaning and preparation	5
A. Prétraitement structurel	5
B. Prétraitement linguistique	7
5. Feature Engineering	12
A. Division du jeu de données	12
B. Transformation des données textuelles	13
C. Représentation du texte par TF-IDF	13
D. Traitement spécifique du domaine scientifique	13
E. Traitement des variables numériques	13
F. Combinaison des caractéristiques et pondération	14
G. Forme finale des données	14
H. Réduction et sélection des caractéristiques	14
6. Data Meaning, Modélisation et Évaluation Métier	15
A. Définition sémantique de la variable cible (Target Meaning)	15
B. Encodage de la variable cible	15
C. Définition d'une métrique métier adaptée	16
D. Entraînement des modèles	16
E. Analyse comparative et interprétation métier	17
F. Conclusion de la partie Data Meaning	18
7. Conclusion	18

1. Business Understanding and problem formulation :

Dans les séminaires scientifiques, de nombreux chercheurs soumettent des articles pour publication. Chaque article doit être évalué et validé par des spécialistes du domaine correspondant (informatique, médecine, droit, économie, etc.).

Actuellement, l'attribution des articles aux spécialistes se fait de manière manuelle, ce qui peut entraîner :

- une perte de temps importante,
- un risque d'erreur dans l'affectation (article envoyé à un spécialiste d'un autre domaine),
- une surcharge pour certains spécialistes alors que d'autres sont sous-utilisés.

Besoins identifiés :

- Automatiser l'affectation des articles aux spécialistes compétents.
- Réduire le temps de gestion et améliorer l'efficacité du processus.
- Garantir que chaque article soit évalué par une personne ayant l'expertise nécessaire.

Dans ce projet, nous cherchons à analyser des textes écrits en arabe afin d'identifier des relations entre le contenu textuel des articles et les reviewers

L'objectif principal est de comprendre comment le vocabulaire, les thèmes et le style d'écriture varient selon le domaine professionnel du reviewer

Ce type d'analyse peut être utile dans plusieurs contextes :

- améliorer la recommandation du reviewer selon le contenu de l'article ;
- assister dans la classification automatique de textes arabes selon leur domaine ;

Ainsi, le problème peut être formulé comme une tâche de classification supervisée :

À partir du texte associé à un article (titre, résumé, mots-clés, etc.), prédire le reviewer le plus approprié.

2. Data collection

A. Collecte des données

La collecte des données constitue une étape fondamentale de ce projet, car la qualité du système de recommandation dépend fortement de la pertinence et de la cohérence des données utilisées. L'objectif principal était de construire une base de données d'articles scientifiques rédigés en langue arabe, accompagnés d'informations fiables sur leurs reviewers, afin de permettre l'apprentissage d'un modèle de recommandation de reviewers basé sur des techniques de classification supervisée.

B. Démarche de collecte

Nous avons adopté une démarche qui repose sur une collecte **manuelle et contrôlée** des données. Nous avons choisi cette approche afin de garantir la fiabilité des informations, notamment l'association entre chaque article scientifique et son reviewer. Pour chaque article sélectionné, Nous avons soigneusement extrait les informations textuelles et contextuelles puis nous les avons organisé sous forme structurée dans un fichier tabulaire.

Une attention particulière a été portée à la diversité des domaines scientifiques, afin d'éviter un biais vers un seul domaine et d'améliorer la capacité de généralisation du modèle de recommandation.

C. Sources des données

Nous avons collecté les données partir de **plusieurs sites web et journaux scientifiques arabes reconnus**, publiant des articles évalués par des reviewers spécialisés. Ces sources incluent des plateformes de revues académiques arabes couvrant différents domaines scientifiques tels que la médecine, le droit, l'ingénierie et les sciences humaines.

Le choix de ces sources a permis d'obtenir :

- des articles scientifiques rédigés en arabe,
- des informations explicites ou déductibles sur les reviewers,
- des indicateurs de qualité comme le facteur d'impact du journal.

D. Outils utilisés

La collecte et l'organisation des données ont été réalisées à l'aide de :

- navigateurs web pour l'exploration des plateformes scientifiques,
- Excel pour la structuration initiale des données,

Ces outils ont permis d'assurer une base de données cohérente, homogène et facilement intégrable dans l'environnement de développement du projet.

E. Résultat de la collecte

À l'issue de cette phase, Nous avons constitué un jeu de données composé de **400 articles scientifiques**. Chaque article est décrit par plusieurs attributs pertinents pour la tâche de recommandation du reviewer :

- **title** : le titre de l'article scientifique,
- **abstract** : le résumé de l'article,
- **keywords** : les mots-clés associés à l'article,
- **domain** : le domaine scientifique de l'article (médecine, droit, ingénierie, etc.),
- **reviewer_profession** : la profession ou la spécialité du reviewer,
- **Impact_Factor** : le facteur d'impact du journal de publication,
- **reviewer** : le nom ou l'identifiant du reviewer (variable cible).

Cette base de données constitue un socle solide pour l'étape suivante du projet, à savoir le prétraitement des données et l'entraînement du modèle de recommandation.

3. Data Understanding (Compréhension des données)

Après la phase de collecte, nous avons procédé à une étape de **compréhension et d'exploration des données**, afin d'analyser leur structure, leur répartition et leur cohérence avant le prétraitement et la modélisation. Cette étape est essentielle pour identifier d'éventuels déséquilibres ou anomalies susceptibles d'influencer les performances du système de recommandation.

Nous avons constitué un jeu de données contenant un total de **400 articles scientifiques** rédigés en langue arabe. Ces articles sont associés à **70 reviewers distincts**, appartenant à différents domaines scientifiques.

Nombre total de reviewers : 70

		reviewer	n_rows
0	10	عبدالله سعود السميري	
1		شريف كمال دسوقي	10
2	10	أنور عبدهللا الغانم	
3	10	منى حمد عبدالله آل عثيوان	
4		سوسن محمد	10
5	10	عبد هلال بن يوسف الجبر	
6	10	خالد صالح الدين الخياط	
7	10	زينة مروان الشريتي	
8	10	سعداء عوض المطرفي	
9	10	علي محمد القاسم	
10	5	غادة بنت خليفة بن حرقوص الراشدية	
11		فالح عواد الحربي	5

Le jeu de données couvre **4 domaines scientifiques** (médecine, droit, ingénierie, les sciences humaines) pour chaque domaine nous avons 100 articles, ce qui permet de prendre en compte la diversité disciplinaire dans le processus de recommandation.

Nombre total de domaines : 4

	domain	n_rows
0	100	اجتماعية
1	100	طب
2	100	قانون
3	100	هندسة

4. Data cleaning and preparation

A. Prétraitement structurel

Le prétraitement structurel vise à corriger les incohérences et à traiter les valeurs manquantes afin d'obtenir un jeu de données propre, cohérent et exploitable pour la phase de modélisation. Dans ce projet, nous avons appliqué plusieurs opérations de nettoyage et d'imputation, décrites ci-dessous.

Tout d'abord, nous avons procédé à la **suppression des doublons**. Les articles présentant le même champ *title* ont été considérés comme redondants et supprimés afin d'éviter toute surreprésentation d'un même contenu lors de l'apprentissage du modèle.

Ensuite, nous avons traité les **informations manquantes liées aux reviewers**. Toutes les lignes pour lesquelles la variable cible *reviewer* était absente, ou dont la *reviewer_profession* était manquante, ont

été supprimées. Ce choix est motivé par le fait que ces informations sont essentielles pour la tâche de recommandation supervisée.

Concernant la variable numérique **Impact_Factor**, nous avons appliqué une stratégie d'imputation. Lorsqu'un article ne disposait pas de cette valeur, celle-ci a été remplacée par la **moyenne des facteurs d'impact des articles associés au même reviewer**. Cette approche permet de conserver l'information tout en respectant la cohérence académique liée au reviewer concerné.

Les **champs textuels** ont également fait l'objet d'un traitement spécifique :

- lorsque le *abstract* était manquant, nous l'avons remplacé par la concaténation du *title* et des *keywords* ;
- lorsque le *title* était manquant, il a été remplacé par les *keywords* ;
- lorsque à la fois le *title* et les *keywords* étaient absents, la ligne correspondante a été supprimée
- lorsque seuls les *keywords* étaient manquants, la ligne a également été supprimée, en raison de l'insuffisance d'informations textuelles.

Enfin, nous avons traité les **valeurs manquantes du champ domain**. Lorsqu'un domaine n'était pas renseigné pour un article, il a été imputé par le **domaine majoritaire des articles évalués par le même reviewer**. Cette méthode permet de préserver la cohérence entre l'expertise du reviewer et le domaine scientifique associé.

L'ensemble de ces opérations a permis d'obtenir un jeu de données **sans doublons, cohérent et complet**, constituant une base fiable pour les étapes suivantes de prétraitement avancé et d'ingénierie des caractéristiques.

	0
title	0
keywords	0
abstract	0
domain	0
reviewer	0
reviewer_profession	0
Impact_Factor	0

dtype: int64

À l'issue de cette phase de nettoyage et de prétraitement structurel, nous avons obtenu un jeu de données final composé de **339 articles scientifiques** associés à **66 reviewers distincts**.

Nombre total de reviewers : 66				... Nombre total de domaines : 4			
		reviewer	n_rows			domain	n_rows
0		10	سوسن محمد	0	89	طب	
1	10		خالد صالح الدين الخياط	1	85	قانون	
2		10	علي محمد القاسم	2	84	هندسة	
3	9		عبد هلال بن يوسف الجبر	3	81	إجتماعية	
4		9	زينة مروان الشربتي				
5	9		أنور عبد هلال الغاتم				

B. Prétraitement linguistique

Étant donné que notre jeu de données est constitué de textes scientifiques rédigés en **langue arabe**, nous avons appliqué un prétraitement linguistique spécifique afin de garantir une représentation textuelle homogène et exploitable par les modèles d'apprentissage automatique.

Nettoyage du texte arabe :

Dans ce cadre, nous avons développé et utilisé une fonction dédiée, **clean_text_ar()**, permettant de nettoyer et normaliser les textes arabes issus des champs *title*, *abstract* et *keywords*.

Cette fonction applique plusieurs opérations successives visant à réduire le bruit linguistique et à standardiser les formes textuelles :

- **Normalisation des caractères arabes** : les différentes variantes de certaines lettres ont été unifiées (par exemple : آ → آ, إ, ا), afin de réduire la diversité artificielle des formes lexicales.
- **Traitement des lettres non standard** : certaines lettres empruntées à d'autres alphabets ou variantes régionales (ڙ, چ, گ, ڦ, ڦ, پ) ont été remplacées par leurs équivalents arabes standards.
- **Suppression des diacritiques arabes** (tashkīl) ainsi que du **tatweel (-)**, qui n'apportent pas d'information sémantique utile pour la tâche de recommandation.
- **Suppression des chiffres**, qu'ils soient écrits en chiffres arabes ou latins.
- **Suppression de la ponctuation et des caractères non arabes**, avec une gestion conditionnelle permettant de conserver ou non certains séparateurs selon le contexte du traitement.
- **Réduction des espaces multiples**, afin d'obtenir un texte propre et correctement segmenté.

Tokenisation et segmentation morphologique :

Après le nettoyage du texte arabe, nous avons appliqué une **tokenisation avancée** à l'aide de la fonction `tokenize_with_segmentation()`.

Contrairement à une tokenisation classique, cette approche prend en compte la **richesse morphologique de la langue arabe**.

Pour ce faire, nous avons utilisé le **MLEDisambiguator** de la bibliothèque *CAMEL Tools*, combiné à un tokenizer de base. Cette méthode permet de segmenter les mots arabes en leurs composantes morphologiques pertinentes.

Les principales opérations réalisées sont les suivantes :

- segmentation morphologique des mots à partir de leur analyse linguistique ;
- élimination des affixes grammaticaux fréquents tels que « ل », « ك », « ب », « و », etc., afin de conserver uniquement les unités lexicales porteuses de sens ;
- nettoyage de chaque segment obtenu en appliquant à nouveau la fonction `clean_text_ar()`, car le processus de désambiguïsation peut introduire des caractères indésirables.


Le résultat de cette étape est une **liste de tokens normalisés et segmentés**, mieux adaptée aux traitements automatiques du texte arabe et à la phase de vectorisation.

Lemmatisation :

Afin de réduire la **variabilité morphologique** et la redondance lexicale, nous avons ensuite appliqué une **lemmatisation** à l'aide de la fonction `lemmatize_tokens()`.

Cette fonction extrait, pour chaque token, sa **forme canonique (lemma)** à partir de l'analyse morphologique fournie par le désambiguïsateur. Lorsque le mot n'est pas reconnu ou que sa racine lexicale n'est pas disponible, sa forme originale nettoyée est conservée.

Cette étape permet de regrouper les différentes formes fléchies d'un même mot sous une représentation unique, ce qui améliore la cohérence des features textuelles et réduit la dimensionnalité de l'espace de représentation.



Traitement spécifique des mots-clés (keywords) :

Contrairement aux autres champs, nous avons choisi de ne pas appliquer de segmentation morphologique ni de lemmatisation aux *keywords*.

Ce choix est motivé par le fait que les mots-clés représentent généralement des termes scientifiques normalisés, dont la structure doit être préservée.

Le prétraitement appliqué aux *keywords* s'est donc limité à :

- l'unification des séparateurs (remplacement de « ; », « – », « - », « | », « ‘ » par une virgule standard),
- la suppression des espaces inutiles autour des virgules,
- le nettoyage des espaces en début et fin de chaîne.

Ainsi, les mots-clés ont été conservés sous une forme structurée, tout en garantissant une cohérence syntaxique.

Suppression des stop words :

Après les étapes de tokenisation et de lemmatisation, les textes contiennent encore de nombreux mots très fréquents mais **pauvres en information sémantique**, tels que les articles, conjonctions et prépositions (par exemple : « أن », « في », « على », « من », etc.). Ces mots, appelés *stop words*, peuvent introduire du bruit dans les représentations vectorielles et réduire la capacité du modèle à discriminer efficacement les articles scientifiques.

Afin de limiter cet effet, nous avons appliqué une suppression des mots vides en deux niveaux : standard et personnalisé.

- **Stop words standard**

Dans un premier temps, nous avons utilisé une **liste standard de stop words arabes** issue du fichier *arabic_stopwords.txt*. Cette liste regroupe les termes les plus courants de la langue arabe qui n'apportent pas d'information contextuelle significative.



Reference des step-words arabe :

```
@misc{alrefaie2019arabic,
  title={Arabic Stop Words},
  author={Alrefaie, Mohamed Taher},
  year={2019}
}
```

Cette première étape de filtrage a permis de réduire significativement la taille du vocabulaire et d'améliorer la pertinence des tokens conservés pour l'analyse textuelle.

- **Stop words personnalisés**

Cependant, la liste standard ne suffit pas toujours dans un contexte applicatif spécifique. Certains mots peuvent être très fréquents dans notre corpus sans pour autant apparaître dans les listes classiques de stop words, tout en n'apportant aucune information discriminante pour la tâche de recommandation.

Pour cette raison, nous avons développé une approche statistique et contextuelle afin d'identifier des stop words personnalisés.


Cette méthode consiste à analyser la distribution des mots à travers l'ensemble des domaines scientifiques présents dans la base de données. Pour chaque mot, nous avons :

- calculé sa fréquence d'apparition dans chaque domaine,
- mesuré la proportion de domaines dans lesquels il est présent.

Lorsqu'un mot apparaît dans la majorité des domaines avec une fréquence relativement équilibrée, il est considéré comme peu discriminant. Il est alors automatiquement identifié comme stop word personnalisé et supprimé du corpus.

Cette approche permet d'adapter dynamiquement la liste de mots vides au contexte spécifique de notre jeu de données, améliorant ainsi la qualité des représentations textuelles et les performances potentielles du modèle de recommandation.

Word cloud avant la suppression des stop words personnalisés



À l'aide de la fonction `analyze_tokens`, nous avons constaté que le mot « دراسة » apparaît de manière très fréquente et uniforme dans l'ensemble des articles, tous domaines confondus. En raison de son faible pouvoir discriminant, ce terme a été considéré comme un stop word personnalisé et a été supprimé du corpus.

	Token	Total_Occurrences	Articles_Count	Count_طب	Count_قانون	Count_هندسة	Count_اجتماعي	Domain_Coverage	Stop_Word
Token_1	دراسة	1019	339	267	258	251	243	1.0	True

Après la suppression des stopwords le nouveau word cloud contient des des mots plus pertinent au model

B. Transformation des données textuelles

Les colonnes textuelles (*title*, *abstract*, *keywords* et *reviewer_profession*) ont été converties en chaînes de caractères simples. Lorsqu'une colonne contenait une liste de mots, ces éléments ont été fusionnés en une seule chaîne.

Nous avons ensuite concaténé l'ensemble de ces colonnes afin de créer **un champ textuel unique par article**, permettant d'exploiter simultanément toutes les informations sémantiques disponibles.

C. Représentation du texte par TF-IDF

Le texte combiné a été transformé en représentation numérique à l'aide de la méthode **TF-IDF (Term Frequency – Inverse Document Frequency)**. Cette technique permet de mesurer l'importance relative d'un mot ou d'un bigramme dans un article par rapport à l'ensemble du corpus.

Nous avons :

- considéré des **uni-grammes et bi-grammes**,
- limité le nombre de caractéristiques textuelles à **5000**, afin de réduire la dimensionnalité tout en conservant les termes les plus informatifs.

Cette étape produit, pour chaque article, un **vecteur TF-IDF** décrivant son contenu textuel.

D. Traitement spécifique du domaine scientifique

La variable **domain** joue un rôle central dans la recommandation du reviewer. Si elle avait été intégrée directement dans la représentation TF-IDF, son poids aurait été **très faible**, car le domaine apparaît une seule fois par article, contrairement aux mots du texte qui peuvent être répétés.

Pour éviter cette sous-pondération et préserver l'importance du domaine, nous avons choisi de le traiter **séparément** à l'aide d'un **One-Hot Encoding**.

Ainsi, chaque domaine est représenté par une variable binaire indépendante, garantissant que cette information clé reste clairement identifiable par le modèle.

E. Traitement des variables numériques

Les variables numériques, en particulier **Impact_Factor**, ont été conservées sous forme numérique et normalisées. Elles ont ensuite été ajoutées directement à la représentation finale afin d'apporter une information quantitative complémentaire au contenu textuel.

F. Combinaison des caractéristiques et pondération

Une fois les différentes représentations obtenues, nous avons procédé à leur **concaténation** afin de former la matrice finale des caractéristiques.

Lors de cette combinaison, nous avons appliqué des **poids différenciés** :

- les caractéristiques TF-IDF ont été conservées avec un poids standard,
- les variables issues du **One-Hot Encoding du domaine ont été volontairement amplifiées**, afin de refléter leur importance dans la prédiction du reviewer,
- les variables numériques ont été intégrées telles quelles.

Cette pondération permet d'équilibrer l'influence des différentes sources d'information et d'éviter que le texte n'écrase des variables essentielles comme le domaine.

G. Forme finale des données

À l'issue de cette démarche, nous avons obtenu une **matrice finale de caractéristiques** :

- **chaque ligne** correspond à un article scientifique,
- **chaque colonne** représente une caractéristique :
 - termes et bigrammes TF-IDF,
 - domaines encodés,
 - variables numériques.

Cette matrice, notée **X_train_final** pour l'entraînement et **X_test_final** pour le test, constitue l'entrée directe du modèle de recommandation du reviewer.

H. Réduction et sélection des caractéristiques

Enfin, afin de limiter la surdimensionnalité et le risque de surapprentissage, nous avons restreint le nombre de caractéristiques textuelles à **5000**. Cette contrainte agit comme une forme de **sélection automatique des features**, en conservant uniquement les mots les plus fréquents et les plus discriminants du corpus.

Pour quelque article Nous avons affiché les 5 mots les plus importants selon TF-IDF

```
0      [ثقافة, دولي, ثقافة, علم, ابعاد, علاقة, ثقافة, دولي]
1      [صحة, نفسي, نفسي, ابعاد, صحة, نفسي, صحة, الغذية]
2      [جريمة, جنائي, جريمة, عجلون, جنائي, قانون, جنائي]
3      [مادة, مركب, مركب, مادة, محلي, مادة, استكشاف, استخدام]
4      [ذكاء, ذكاء, اصطناعي, اصطناعي, اداء, ذكاء, الاصطناعي]
dtype: object
```

6. Data Meaning, Modélisation et Évaluation Métier

Dans cette partie, nous nous sommes concentrés sur le sens métier des données, la définition correcte de la variable cible, ainsi que sur la mise en place d'une évaluation adaptée au problème réel de recommandation de reviewers. L'objectif n'est pas uniquement de prédire un nom, mais de recommander un reviewer compétent dans le domaine scientifique de l'article.

A. Définition sémantique de la variable cible (Target Meaning)

Initialement, la variable cible était le nom du reviewer. Cependant, cette représentation peut conduire à des erreurs conceptuelles, car un même reviewer peut intervenir dans plusieurs domaines scientifiques. Dans un système de recommandation réel, il est essentiel de distinguer un reviewer selon son domaine d'expertise.

Pour éviter cette ambiguïté, nous avons créé un identifiant unique métier, appelé *reviewer_id*, en combinant :

- le nom du reviewer,
- le domaine scientifique associé.

Ainsi, chaque reviewer est représenté par un couple (reviewer, domaine), garantissant une correspondance claire entre l'article et l'expertise du reviewer.

Cette étape est cruciale pour éviter qu'un reviewer soit recommandé dans un domaine qui ne correspond pas à son champ de compétence.

B. Encodage de la variable cible

Après avoir défini cette nouvelle variable cible, nous avons procédé à l'encodage des labels pour les ensembles d'entraînement et de test.

Cet encodage permet de transformer les identifiants métier (*reviewer / domaine*) en valeurs numériques exploitables par les modèles de classification supervisée.

L'encodage a été ajusté sur l'ensemble d'entraînement, puis appliqué à l'ensemble de test, afin de garantir la cohérence et d'éviter toute fuite d'information.

C. Définition d'une métrique métier adaptée

Les métriques classiques comme l'accuracy ne sont pas toujours suffisantes pour évaluer un système de recommandation. En pratique, il est acceptable de proposer plusieurs reviewers pertinents, tant qu'ils appartiennent au bon domaine.

Pour cette raison, nous avons défini une métrique métier personnalisée, appelée *business score*, qui prend en compte :

- la similarité entre le domaine du reviewer prédit et celui du reviewer réel,
- la position du reviewer correct dans la liste des recommandations.

Le principe est le suivant :

- un score partiel est accordé si les domaines du reviewer réel et du reviewer prédit partagent au moins un mot commun,
- le score augmente avec le nombre de reviewers pertinents recommandés,
- un score maximal de **1.0** est attribué si le reviewer exact (nom + domaine) est correctement prédit.

Cette métrique reflète mieux la qualité réelle de la recommandation que l'accuracy classique.

D. Entraînement des modèles

Après la préparation des données et la définition des métriques, nous avons procédé à l'entraînement de deux modèles de classification supervisée afin de comparer leurs performances.

Premier modèle : Régression Logistique

Le premier modèle utilisé est une régression logistique multiclasse. Ce modèle linéaire constitue une base de référence robuste et interprétable.

Les résultats obtenus sont les suivants :

- **Score métier final : 0.93**
- **Accuracy classique : 0.5294**

- **Top-1 Accuracy : 0.5294**
- **Top-3 Accuracy : 0.7294**
- **Top-5 Accuracy : 0.8353**

Ces résultats montrent que, bien que l'accuracy classique soit relativement modérée, le modèle est capable de proposer des reviewers pertinents dans les premières recommandations. Le score métier élevé confirme que les reviewers suggérés appartiennent majoritairement au bon domaine.

Deuxième modèle : Random Forest

Le second modèle est une Random Forest, capable de capturer des relations non linéaires complexes entre les caractéristiques. Nous avons également pris en compte le déséquilibre des classes grâce au paramètre *class_weight*.

Les performances obtenues sont nettement supérieures :

- **Score métier final : 1.00**
- **Accuracy classique : 0.9176**
- **Top-1 Accuracy : 0.9176**
- **Top-3 Accuracy : 1.0000**
- **Top-5 Accuracy : 1.0000**

Ces résultats indiquent que le modèle parvient non seulement à identifier le reviewer exact dans la majorité des cas, mais aussi à proposer des listes de recommandations parfaitement pertinentes.

E. Analyse comparative et interprétation métier

La comparaison entre les deux modèles met en évidence plusieurs points :

- la régression logistique offre une bonne base mais reste limitée face à la complexité des données textuelles,
- la Random Forest exploite plus efficacement la richesse des features combinées (texte, domaine, facteurs numériques),
- les métriques métier et Top-k sont plus représentatives de la performance réelle du système que l'accuracy seule.

D'un point de vue métier, le second modèle répond pleinement à l'objectif du projet : recommander des reviewers compétents, spécialisés et pertinents pour chaque article scientifique.

F. Conclusion de la partie Data Meaning

Cette étape a permis de donner un **sens métier fort aux données**, en alignant la modélisation, la variable cible et les métriques d'évaluation avec le problème réel de recommandation. Les résultats obtenus confirment que la prise en compte du domaine scientifique et l'utilisation de métriques adaptées sont essentielles pour construire un système de recommandation fiable et performant.

7. Conclusion

Dans ce projet, nous avons développé un système de recommandation de reviewers pour des articles scientifiques en arabe, en suivant une démarche structurée allant de la collecte et la compréhension des données au prétraitement linguistique, à l'ingénierie des features et à la modélisation supervisée.

Nous avons accordé une attention particulière à la signification métier des données, en définissant un identifiant unique pour chaque reviewer combiné à son domaine d'expertise. Cette approche a permis de créer un modèle capable de proposer des reviewers pertinents dans le bon domaine, même lorsque l'accuracy classique ne reflète pas entièrement la performance réelle.

L'utilisation de métriques adaptées au contexte métier et de modèles robustes tels que la Random Forest a montré que notre système pouvait atteindre un score métier parfait, confirmant son efficacité pour la recommandation.

Ce projet démontre l'importance de combiner prétraitement textuel avancé, représentation adaptée des données et évaluation métier spécifique, afin de concevoir des systèmes de recommandation précis et fiables. Pour les travaux futurs, il serait intéressant d'explorer des approches basées sur l'apprentissage profond ou les embeddings contextuels, pour encore mieux capturer la sémantique des articles et améliorer la qualité des recommandations.